

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ



BÀI TẬP KẾT THÚC MÔN HỌC

THIẾT KẾ VÀ PHÂN TÍCH THỰC NGHIỆM

Giảng viên: Nguyễn Hải Châu

Sinh viên: Ngô Đức Thịnh

Mã sinh viên: 23020574

Lớp học phần : INT3228E 1

MỤC LỤC

1. Giới thiệu bộ dữ liệu	3
1.1. Mô tả dữ liệu	3
1.2. Tiền xử lý dữ liệu và Chọn lọc đặc trưng	3
2. Xây dựng Mô hình Cơ sở (Mô hình M)	5
2.1. Thiết lập mô hình	5
2.2. Phân tích hiệu năng bằng $lm()$ và Đánh giá tầm quan trọng đặc trưng	5
3. Thí nghiệm CRD (Completely Randomized Design)	7
3.1. Thiết kế thí nghiệm	7
3.2. Kết quả mô tả thống kê	7
3.3. Kiểm định tính đồng nhất phương sai (Levene's Test)	7
3.4. Phân tích phương sai một chiều (One-way ANOVA)	8
3.5. So sánh bội hậu định (Tukey HSD)	8
4. Thí nghiệm CRFD (Completely Randomized Factorial Design)	9
4.1. Thiết kế thí nghiệm	9
4.2. Bảng thống kê mô tả	9
4.3. Đánh giá ảnh hưởng của các yếu tố độc lập (Main Effects)	10
4.4. Phân tích tác động tương tác (Interaction Effect)	11
5. Kết luận	12
5.1. Tóm tắt kết quả	12
5.2. Khuyến nghị triển khai	13

1. Giới thiệu bộ dữ liệu

1.1. Mô tả dữ liệu

Bộ dữ liệu mlc_churn chứa dữ liệu rời mạng viễn thông của các thuê bao ở một công ty viễn thông Mỹ. Mỗi dòng trong bộ dữ liệu chứa thông tin sử dụng dịch vụ của một khách hàng trong một khoảng thời gian nhất định, ví dụ số phút gọi, số cuộc gọi, cước vào ngày, đêm, lễ, quốc tế..., vị trí địa lý, thời gian đã sử dụng dịch vụ của công ty.. và trạng thái rời mạng: churn yes là đã rời mạng, churn=no ngược lại.

Thông Số	Giá Trị
Số mẫu	5000
Cột đặc trưng	20 cột
Khách hàng “yes”	4.293 (85,86%)
Khách hàng “no”	707 (14,14%)


Phân loại và ý nghĩa các cột (biến):

Các biến trong bộ dữ liệu được chia thành 4 nhóm thông tin chính:

- **Nhóm thông tin vị trí và tài khoản:** Bao gồm vị trí địa lý, thời gian đã sử dụng dịch vụ của công ty. Gồm các cột cụ thể: state (Mã bang), area_code (Mã vùng điện thoại), account_length (Số ngày tài khoản đã hoạt động).
- **Nhóm thông tin mức độ sử dụng và cước phí:** Ghi nhận chi tiết số phút gọi, số cuộc gọi, cước vào ngày, đêm, lễ, quốc tế.... Được chia thành 4 mốc thời gian/loại hình gồm: ban ngày (day), buổi tối (eve), ban đêm (night) và quốc tế (intl). Mỗi loại hình này đều có 3 cột tương ứng là số phút gọi (minutes), số cuộc gọi (calls) và cước phí (charge).
- **Nhóm thông tin gói cước và dịch vụ khách hàng:** Gồm các cột cụ thể: international_plan (Có dùng gói quốc tế hay không), voice_mail_plan (Có dùng gói hộp thư thoại hay không), number_vmail_messages (Số lượng tin nhắn thoại), và number_customer_service_calls (Số lần gọi khiếu nại/hỗ trợ từ tổng đài).
- **Biến mục tiêu (Target Variable):** Cột churn thể hiện trạng thái rời mạng: churn yes là đã rời mạng, churn=no ngược lại.

1.2. Tiền xử lý dữ liệu và Chọn lọc đặc trưng

Quá trình tiền xử lý dữ liệu được thực hiện nhằm loại bỏ các thông tin dư thừa, giảm nhiễu và tối ưu hóa hiệu suất học của mô hình Random Forests. Dựa trên việc phân tích mức độ tương quan và ý nghĩa thực tiễn của các biến, các bước xử lý sau đã được áp dụng:



Hình 1: Ma trận tương quan giữa các biến số định lượng.

- Xử lý hiện tượng đa cộng tuyến (Multicollinearity):** Thông qua việc trích xuất và tính toán ma trận tương quan (Correlation Matrix) cho các biến số liên tục, kết quả cho thấy tồn tại sự tương quan tuyến tính hoàn hảo (hệ số tương quan $r = 1.0$) giữa các cặp biến số phút gọi và cước phí tương ứng. Cụ thể là các cặp: *total_day_minutes* và *total_day_charge*, *total_eve_minutes* và *total_eve_charge*, *total_night_minutes* và *total_night_charge*, *total_intl_minutes* và *total_intl_charge*. Về mặt ý nghĩa thực tiễn, cước phí được tính toán trực tiếp từ số phút sử dụng. Việc giữ lại cả hai biến trong mô hình không cung cấp thêm lượng thông tin dự báo mới mà còn gây ra sự dư thừa dữ liệu. Do đó, quyết định được đưa ra là loại bỏ toàn bộ 4 biến cước phí (charge) và chỉ giữ lại 4 biến số phút gọi (minutes).

- **Loại bỏ các biến định danh thiếu tính khái quát:** Các biến định danh vị trí địa lý bao gồm *state* (mã bang) và *area_code* (mã vùng) chứa số lượng phân nhóm (levels) rất lớn nhưng tần suất của mỗi nhóm lại tương đối nhỏ. Trong bài toán phân tích hành vi rời mạng tổng quát, các biến này mang tính chất cục bộ, không đóng góp nhiều vào việc khái quát hóa quy luật dự báo và dễ dẫn đến hiện tượng quá khớp (overfitting) cho các mô hình cây quyết định. Do đó, hai biến *state* và *area_code* đã được loại bỏ khỏi tập dữ liệu.

2. Xây dựng Mô hình Cơ sở (Mô hình M)

2.1. Thiết lập mô hình

Mô hình M sử dụng thuật toán Random Forests (gói *tidymodels*, engine *ranger*) với các siêu tham số mặc định (không giới hạn độ sâu của cây) nhằm đánh giá năng lực dự đoán gốc. Để đảm bảo tính tái lập tuyệt đối cho kết quả, hạt giống ngẫu nhiên được cố định (*seed* = 1234) và engine được cấu hình chạy đơn luồng (*num.threads* = 1).

Mô hình được huấn luyện bằng chiến lược chia fold phân tầng (stratified repeated k-fold) với *k*=5, lặp 10 lần. Lớp "yes" (đã rời mạng) được chủ động thiết lập làm lớp tích cực (positive class) nhằm tối ưu hóa và đo lường chính xác hiệu năng qua độ đo F1-Score.

2.2 Phân tích hiệu năng bằng *lm()* và Đánh giá đặc trưng

Để tổng hợp kết quả từ 50 điểm đánh giá (5 fold x 10 lần lặp) kèm theo giá trị trung bình và khoảng tin cậy, mô hình hồi quy tuyến tính *lm()* với công thức *.estimate* ~ 1 đã được áp dụng.

```
>> Kết quả F1-Score trung bình (rút gọn) của Mô hình M:
> print(f1_M_summary)
# A tibble: 1 x 6
  .metric .estimator mean      n std_err .config
  <chr>   <chr>    <dbl> <int>   <dbl> <chr>
1 f_meas binary    0.810    50 0.00372 pre0_mod0_post0
```

```
[1] ">> Bảng tóm tắt hồi quy lm() cho F1-Score:"
> print(summary(lm_M))

Call:
lm(formula = .estimate ~ 1, data = f1_scores_M)

Residuals:
    Min       1Q   Median       3Q      Max
-0.051557 -0.018736 -0.000174  0.019094  0.065110


Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.809890    0.003724   217.5  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.02633 on 49 degrees of freedom

>
> print(">> Khoảng tin cậy 95% của F1-Score:")
[1] ">> Khoảng tin cậy 95% của F1-Score:"
> print(confint(lm_M))
              2.5 %      97.5 %
(Intercept) 0.8024074 0.8173732
>
```

Kết quả phân tích cho thấy F1-Score trung bình của Mô hình cơ sở đạt **0.8099** (sai số chuẩn rất thấp $SE = 0.0037$), với khoảng tin cậy 95% nằm trong dải hẹp từ **[0.8024, 0.8174]**. Mức điểm này phản ánh năng lực nhận diện nhóm khách hàng rời mạng của Random Forest là rất ấn tượng và có độ ổn định cao ngay cả khi chưa tính chỉnh siêu tham số.

Đồng thời, kết quả trích xuất mức độ giảm độ nhiễu (Impurity reduction) từ thuật toán chỉ ra rõ ràng: *total_day_minutes*, *number_customer_service_calls* và *total_eve_minutes* là 3 biến mang tính quyết định, đóng góp lớn nhất vào khả năng dự đoán của hệ thống.



3. Phân tích Thí nghiệm Ngẫu nhiên Hoàn toàn (CRD)

3.1. Thiết kế thí nghiệm

Thí nghiệm CRD được thiết kế để đánh giá ảnh hưởng của số lượng fold chia dữ liệu (k) đến hiệu năng của mô hình. Yếu tố khảo sát duy nhất là k với 3 mức độ: $k = 3, 5, 10$. Mô hình Random Forest (RF) sử dụng cấu hình không giới hạn độ sâu cây ($\text{max_depth} = \text{mặc định}$), với phương pháp kiểm chứng chéo lặp lại 10 lần ($\text{repeats} = 10$). Quá trình chia fold được thực hiện theo chiến lược phân tầng (stratified) nhằm đảm bảo tỷ lệ lớp mục tiêu (khách hàng rời mạng) luôn được cân bằng trong các tập huấn luyện và kiểm định.

Tổng số lượng mẫu đo lường (điểm F1) thu được tương ứng là: $k=3$ có 30 kết quả, $k=5$ có 50 kết quả và $k=10$ có 100 kết quả.

3.2. Kết quả mô tả thống kê

Bảng dưới đây tóm tắt các tham số thống kê mô tả cho độ đo F1-Score theo từng nhóm k :

	k	N_mau	Trung_binh_F1	Std	CI_95%(+/-)	Min	Max
1	3	30	0.8008	0.02475	0.009240	0.7506	0.8491
2	5	50	0.8099	0.02633	0.007483	0.7583	0.8750
3	10	100	0.8170	0.03207	0.006364	0.7419	0.8939

3.3. Kiểm tra giả định (Levene's Test)

Trước khi tiến hành phân tích phương sai, kiểm định Levene (Levene's Test) được thực hiện để kiểm tra giả định về tính đồng nhất của phương sai độ đo F1 giữa 3 nhóm k :

```
Levene's Test for Homogeneity of Variance (center = median)
      Df F value Pr(>F)
group  2  2.6304 0.07486 .
      177
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Với $p = 0.07486 > 0.05$, ta chấp nhận giả thuyết H_0 (phương sai giữa các nhóm là bằng nhau). Việc phương sai đồng nhất chứng tỏ dữ liệu hoàn toàn thỏa mãn giả định khắt khe nhất để tiến hành phân tích phương sai một chiều (ANOVA) ở bước tiếp theo. Mặc dù quan sát thực tế độ lệch chuẩn có tăng nhẹ khi $k=10$, nhưng sự chênh lệch này chỉ là ngẫu nhiên và không vi phạm điều kiện thống kê.

3.4. Phân tích phương sai một chiều (One-way ANOVA)

ANOVA một chiều được sử dụng để kiểm định xem giá trị trung bình F1 giữa các nhóm \$k\$ có thực sự khác biệt mang ý nghĩa thống kê hay không:

```
      Df Sum Sq Mean Sq F value Pr(>F)
k      2  0.00645  0.003226   3.719  0.0262 *
Residuals 177  0.15356  0.000868
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Nhận xét: Khác với các quan sát ban đầu, khi loại bỏ hoàn toàn nhiễu đa luồng của thuật toán, kiểm định ANOVA cho kết quả $F = 3.719$ với $p = 0.0262 < 0.05$. Do đó, ta có đủ bằng chứng thống kê để **bác bỏ giả thuyết H_0** (trung bình F1 bằng nhau ở cả 3 mức k). Kết luận là số lượng fold k thực sự có ảnh hưởng mang ý nghĩa thống kê đến hiệu năng phân loại của mô hình.

3.5. So sánh bội (Tukey HSD)


Để xác định chính xác sự khác biệt nằm ở cặp k nào, kiểm định hậu định Tukey HSD được áp dụng:

```
Tukey multiple comparisons of means
95% family-wise confidence level

Fit: aov(formula = F1 ~ k, data = crd_data)

$k
      diff      lwr      upr      p adj
5-3  0.009042312 -0.007035406  0.02512003  0.3808299
10-3 0.016172660  0.001680401  0.03066492  0.0245487
10-5 0.007130348 -0.004927941  0.01918864  0.3443143
```

Nhận xét Tukey HSD: Phân tích chỉ ra rằng sự khác biệt tổng thể trong ANOVA chủ yếu đến từ sự vượt trội của cấu hình $k=10$ so với $k=3$. Cụ thể, mô hình chạy với 10-fold có điểm F1 trung bình cao hơn mô hình 3-fold là 0.0162, và sự cải thiện này là **mang ý nghĩa thống kê** ($p\text{-adj} = 0.0245 < 0.05$). Khoảng tin cậy của cặp này (0.0017 đến 0.0307) cũng không chứa giá trị 0, củng cố thêm độ vững chắc của kết luận. Các cặp còn lại (5 vs 3, và 10 vs 5) có sự chênh lệch nhưng chưa đủ lớn để đạt ý nghĩa thống kê ($p\text{-adj} > 0.05$).



Hình 3: Boxplot phân phối F1 theo số lượng fold k. Trung bình F1 và khoảng tin cậy 95%. Với thiết lập loại bỏ nhiễu hệ thống, $k = 10$ cho thấy sự cải thiện hiệu năng rõ rệt và tạo ra khác biệt có ý nghĩa thống kê so với $k = 3$

4. Thí nghiệm CRFD (Completely Randomized Factorial Design)

4.1. Thiết kế thí nghiệm

Thí nghiệm đa yếu tố hoàn toàn ngẫu nhiên (CRFD) được thiết lập để đánh giá tác động đồng thời của hai yếu tố lên hiệu năng mô hình (F1-Score):

1. **Số lượng fold (k):** Nhận 3 mức giá trị 3, 5, và 10.
2. **Độ sâu tối đa của cây (max_depth):** Nhận 3 mức giá trị 3, 5, và Không giới hạn (Unlimited).

Thí nghiệm tạo ra $3 \times 3 = 9$ tổ hợp cấu hình. Tương tự thí nghiệm CRD, phương pháp huấn luyện kiểm chứng chéo phân tầng với 10 lần lặp (repeats = 10) được áp dụng. Thuật toán Random Forest được cấu hình chạy đơn luồng (num.threads = 1) và cố định hạt giống ngẫu nhiên nhằm loại bỏ mọi nhiễu hệ thống.

4.2. Bảng thống kê mô tả

Bảng dưới đây tổng hợp các giá trị thống kê mô tả (Trung bình, Độ lệch chuẩn, và Biên độ Khoảng tin cậy 95%) cho từng tổ hợp cấu hình:

	k	max_depth	N_mau	Trung_binh_F1	Std	CI_95%(+/-)
1	3		30	0.03600	0.01473	0.005501
2	3		50	0.45262	0.03984	0.014877
3	3	Unlimited	30	0.80085	0.02475	0.009240
4	5		50	0.03828	0.01995	0.005670
5	5		50	0.47982	0.04135	0.011753
6	5	Unlimited	50	0.80989	0.02633	0.007483
7	10		100	0.05432	0.02471	0.004904
8	10		100	0.50559	0.06010	0.011925
9	10	Unlimited	100	0.81702	0.03207	0.006364

4.3. Đánh giá ảnh hưởng của k và max_depth đến hiệu năng của mô hình

Kết quả phân tích phương sai hai chiều (Two-way ANOVA) cho thấy cả hai yếu tố chính đều có tác động cực kỳ mạnh mẽ và mang ý nghĩa thống kê tuyệt đối đến hiệu năng mô hình ($p\text{-value} < 2e-16$).

```

              Df Sum Sq Mean Sq    F value    Pr(>F)
k              2   0.32   0.158    112.445 < 2e-16 ***
max_depth      2  49.50  24.751  17663.919 < 2e-16 ***
k:max_depth    4   0.02   0.005     3.875 0.00412 **
Residuals    510   0.71   0.001
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
21 observations deleted due to missingness

```

Ảnh hưởng của max_depth (Yếu tố quyết định): Với trị số F không lồ (17663.9), độ sâu của cây là yếu tố đóng vai trò sinh tử. Dựa trên ước lượng từ mô hình hồi quy tuyến tính `lm()`, ta thấy:

- Ở độ sâu 3: Mô hình bị thiếu khớp (underfitting) quá mức, gần như không thể nhận diện được khách hàng rời mạng. F1 trung bình rơi vào vùng cực thấp (khoảng tin cậy 95% chỉ từ 0.022 đến 0.062 ở tất cả các mức k).
- Ở độ sâu 5: Mô hình bắt đầu nắm bắt được quy luật, đẩy F1 trung bình lên ngưỡng 0.452 đến 0.505.
- Khi Không giới hạn (Unlimited): Cây phát triển tối đa, phân loại xuất sắc với điểm F1 trung bình chạm mốc 0.800 đến 0.817.

Ảnh hưởng của k: Yếu tố số lượng fold cũng tạo ra sự khác biệt lớn ($F = 112.4$). Ở bất kỳ thiết lập độ sâu nào, mức $k = 10$ luôn mang lại kết quả F1 cao nhất do cung cấp lượng dữ liệu dồi dào nhất (90% tập gốc) cho mỗi chu kỳ huấn luyện.


4.4. Kiểm tra ý nghĩa thống kê tương tác của k và max_depth

Bên cạnh ảnh hưởng độc lập, điểm nhấn quan trọng nhất của phân tích Two-way ANOVA là phát hiện ra **sự tương tác mang ý nghĩa thống kê** giữa hai yếu tố k và max_depth ($F = 3.875$, p-value = $0.00412 < 0.05$).


Giải thích ý nghĩa của sự tương tác: Hiệu ứng tương tác này cho thấy mức độ cải thiện hiệu năng khi gia tăng lượng dữ liệu huấn luyện (k) không đồng đều, mà phụ thuộc chặt chẽ vào độ sâu của cây:

- Khi thuật toán bị giới hạn quá nghiêm ngặt ($\text{max_depth} = 3$), mô hình bị "nghẽn cổ chai" về năng lực học. Do đó, việc cung cấp thêm nhiều dữ liệu huấn luyện (tăng k từ 3 lên 10) chỉ giúp F1 tăng rất nhẹ (từ 0.036 lên 0.054).
- Ngược lại, khi thuật toán được nới lỏng để có sức chứa lớn hơn ($\text{max_depth} = 5$), việc gia tăng dữ liệu (k từ 3 lên 10) tạo ra sức bật mạnh mẽ hơn hẳn, kéo F1 tăng vọt từ 0.452 lên 0.505 (tăng hơn 0.05 điểm).

Thực nghiệm này chứng minh một nguyên lý quan trọng trong học máy: **Lượng dữ liệu lớn (k=10) chỉ thực sự phát huy tối đa giá trị khi thuật toán được cấp đủ độ phức tạp (max_depth) để học hỏi các đặc trưng**. Sự phân kỳ về độ dốc này được thể hiện rất trực quan thông qua Đồ thị tương tác (Interaction Plot) dưới đây.



Hình 4: (Trái) Đồ thị tương tác - sự phân kỳ về độ dốc giữa các đường cấu hình xác nhận có tồn tại tương tác mang ý nghĩa thống kê giữa k và max_depth. (Phải) Heatmap giá trị F1 trung bình, minh họa sự vượt trội của cấu hình Unlimited kết hợp k=10



Hình 5: Boxplot phân phối độ đo F1 của 9 tổ hợp cấu hình ($k \times \text{max_depth}$) trong thí nghiệm CRFD. Biểu đồ minh họa trực quan sự phân tầng hiệu năng khổng lồ do yếu tố max_depth tạo ra. Cấu hình Unlimited (màu đỏ) luôn đạt F1 cao nhất ở mọi mức k , đồng thời $k=10$ cho thấy mức độ cải thiện và độ ổn định tốt nhất.

5. Kết luận

5.1. Tóm tắt kết quả

Dựa trên chuỗi thực nghiệm khắt khe đã loại bỏ nhiều đa luồng hệ thống, các phát hiện kỹ thuật quan trọng được tóm tắt như sau:

Vấn đề nghiên cứu	Kết quả thực nghiệm rút ra
Mô hình M (Cơ sở)	Thuật toán Random Forest ($\text{max_depth} = \text{Unlimited}$, $k=5$) cho hiệu năng rất tốt với $F1 = 0.8099$. Ba đặc trưng quan trọng nhất lần lượt là: <code>total_day_minutes</code> , <code>number_customer_service_calls</code> và <code>total_eve_minutes</code> .
CRD - Ảnh hưởng của k	Kiểm định Levene xác nhận phương sai đồng nhất ($p = 0.0749$). ANOVA khẳng định k có ảnh hưởng mang ý nghĩa thống kê ($p = 0.0262$). Phân tích Tukey HSD chứng minh cấu hình $k=10$ vượt trội có ý nghĩa so với $k=3$ ($p\text{-adj} = 0.0245$).

CRFD - Ảnh hưởng của max_depth	Là yếu tố mang tính sinh tử ($p < 2e-16$). Cấu hình Unlimited mang lại kết quả xuất sắc (> 0.81). Mức max_depth=5 ở ngưỡng trung bình (~ 0.50). Mức max_depth=3 gây ra hiện tượng thiếu khớp (underfitting) nghiêm trọng, mất hoàn toàn khả năng phân loại (~ 0.04).
CRFD - Ảnh hưởng của k	Trong mô hình đa yếu tố, k tiếp tục thể hiện sự ảnh hưởng cực kỳ lớn đến hiệu năng mô hình ($F = 112.4, p < 2e-16$).
Tương tác k x max_depth	Có ý nghĩa thống kê ($p = 0.0041$). Đồ thị tương tác có sự phân kỳ: Việc tăng k giúp F1 tăng vọt ở độ sâu 5, nhưng gần như vô tác dụng khi cây quá nông (độ sâu 3).

5.2. Khuyến nghị triển khai

Từ các kết luận thống kê trên, nghiên cứu đưa ra các khuyến nghị tối ưu hóa cho bài toán dự đoán khách hàng rời mạng như sau:

- **Về siêu tham số max_depth:** Tuyệt đối tránh việc thiết lập độ sâu cây quá nông (như mức 3) vì nó sẽ triệt tiêu hoàn toàn khả năng nhận diện lớp thiểu số của hệ thống. Khuyến nghị chọn max_depth = Unlimited (không giới hạn) để thuật toán có đủ không gian học hỏi các quy luật phi tuyến tính phức tạp trong hành vi viễn thông của khách hàng.
- **Về chiến lược chia fold (k):** Trái với các thiết lập thông thường, cấu hình $k = 10$ được khuyến nghị mạnh mẽ. Phân tích thống kê đã chứng minh mức $k=10$ cung cấp lượng dữ liệu tối đa (90% tập gốc) cho mỗi chu kỳ huấn luyện, tạo ra sự vượt trội về F1-Score so với việc chia fold nhỏ, đặc biệt là khi kết hợp cùng độ sâu cây lớn.
- **Xử lý mất cân bằng lớp:** Việc chủ động thiết lập lớp tích cực (positive class) là "yes" kết hợp chia mẫu phân tầng (Stratified k-fold) đã hoạt động rất hiệu quả. Trong các nghiên cứu tiếp theo, có thể thử nghiệm tích hợp thêm thuật toán sinh mẫu nhân tạo (SMOTE) hoặc gán trọng số lớp (class_weight) để xem có thể đẩy F1-Score vượt mức 0.82 hay không.
- **Tăng cường năng lực mô hình:** Bên cạnh việc tinh chỉnh cây quyết định, có thể áp dụng kỹ thuật Feature Engineering tạo ra các biến mới (Ví dụ: tỷ lệ cước phí ngày/đêm, cước phí trung bình mỗi cuộc gọi) dựa trên 3 biến quan trọng nhất đã tìm ra ở Mô hình M. Đồng thời, có thể khảo sát thêm sự tương tác với các siêu tham số khác như số lượng cây ($n_estimators$) hoặc số mẫu tối thiểu ở nút lá ($min_samples_leaf$).